## Projeto04

July 3, 2019

## 1 Data Science Academy

#### 2 Formação Cientista de Dados

### 2.1 Projeto 04 - Prevendo Customer Churn em Operadoras de Telecom

Este notebook contém as seguintes fases para a análise dos modelos de Machine Learning - Pré-Processamento - Criação do Modelo de Machine Learning - Validação e Otimização do Modelo -Previsão e Relatorios

### 2.2 Definição do Problema de Negócio

Prever o Customer Churn em uma Operadora de Telecom.

Os datasets de treino e de teste estão no diretório /data em anexo a este projeto. O objetivo e criar um modelo de aprendizagem de maquina que possa prever se um cliente pode ou nao cancelar seu plano e qual a probabilidade de isso ocorrer. O cabecalho do dataset e uma descricao do tipo de informação em cada coluna.

### 2.2.1 Informações sobre os atributos:

Unnamed state account\_length area code international\_plan voice\_mail\_plan number\_vmail\_messages total\_day\_minutes total\_day\_calls total\_day\_charge total\_eve\_minutes total\_eve\_calls total\_eve\_charge total\_night\_minutes total\_night\_calls total\_night\_charge total\_intl\_minutes

```
total_intl_calls
total_intl_charge
number_customer_service_calls
churn
```

#### 2.2.2 GOAL

- Os arquivos projeto4\_telecom\_treino.csv e projeto4\_telecom\_teste.csv estão anexos no diretório /data
- Objetivo é prever o Customer Churn em uma Operadora de Telecom (coluna CHURN)
- O modelo é avalidado pelo SCORE e ROC Curve / AUC

#### 2.3 Extraindo e Carregando os Dados

import warnings

```
In [1]: # Importando bibliotecas que serao utilizadas neste projeto
        import warnings
        warnings.filterwarnings("ignore")
        import pandas as pd
        import numpy as np
        import seaborn as sns
        import itertools
        import matplotlib.pyplot as plt
        %matplotlib inline
        # Models
        from sklearn.linear_model import LogisticRegression
        from sklearn.ensemble import ExtraTreesClassifier, RandomForestClassifier
        from sklearn.tree import DecisionTreeClassifier
        from sklearn.neighbors import KNeighborsClassifier
        from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
        from sklearn.naive_bayes import GaussianNB
        from sklearn.svm import SVC
        from xgboost import XGBClassifier
        # Stats
        from scipy import stats
        from scipy.stats import skew, norm
        #Misc
        from sklearn.preprocessing import scale, StandardScaler, MinMaxScaler
        from sklearn.model_selection import KFold, cross_val_score, train_test_split, GridSear
        from sklearn.metrics import confusion_matrix, accuracy_score, classification_report, re
        from sklearn.metrics import precision_recall_curve, f1_score, auc, average_precision_s
        from imblearn.over_sampling import SMOTE
        # Ignore useless warnings
```

```
warnings.filterwarnings(action="ignore")
        pd.set_option('display.max_columns', None)
In [2]: # Carregando arquivo csv usando Pandas
        train = pd.read_csv("data/dataset_treino.csv", header = 0)
        test = pd.read_csv("data/dataset_teste.csv", header = 0)
2.4 Análise Exploratória de Dados
In [3]: # Visualizando o shape do dataset
        # Dataset de Treino (3.333 linhas x 21 colunas)
        # Dataset de Teste (1.667 linhas x 21 colunas)
        train.shape, test.shape
Out[3]: ((3333, 21), (1667, 21))
In [4]: # Visualizando as 5 primeiras linhas do dataset de treino
        train.head()
Out [4]:
                              account_length
                                                   area_code international_plan
           Unnamed: 0 state
        0
                    1
                                               area code 415
                          KS
                                          128
        1
                    2
                          OH
                                          107
                                               area_code_415
                                                                              no
                    3
                          NJ
                                          137
                                               area_code_415
                                                                              no
        3
                          OH
                                          84
                                               area_code_408
                                                                             yes
        4
                    5
                          OK
                                           75
                                               area_code_415
                                                                             yes
                                                    total_day_minutes
                                                                       total_day_calls \setminus
          voice_mail_plan number_vmail_messages
        0
                                                                 265.1
                                                                                     110
                       yes
        1
                       yes
                                                26
                                                                 161.6
                                                                                     123
        2
                                                 0
                                                                 243.4
                                                                                     114
                        no
        3
                                                 0
                                                                 299.4
                                                                                      71
                        nο
        4
                                                 0
                                                                 166.7
                        no
                                                                                     113
           total_day_charge
                             total_eve_minutes total_eve_calls total_eve_charge \
        0
                       45.07
                                           197.4
                                                                99
                                                                                16.78
        1
                       27.47
                                                                                16.62
                                           195.5
                                                               103
        2
                       41.38
                                           121.2
                                                               110
                                                                                10.30
        3
                       50.90
                                            61.9
                                                                88
                                                                                5.26
        4
                       28.34
                                           148.3
                                                               122
                                                                                12.61
                                total_night_calls total_night_charge
           total_night_minutes
        0
                          244.7
                                                 91
                                                                   11.01
        1
                          254.4
                                                                   11.45
                                                103
        2
                          162.6
                                                                    7.32
                                                104
        3
                          196.9
                                                 89
                                                                    8.86
        4
                          186.9
                                                121
                                                                    8.41
           total_intl_minutes total_intl_calls total_intl_charge \
        0
```

3

2.70

10.0

```
2
                          12.2
                                                5
                                                                 3.29
        3
                           6.6
                                                7
                                                                 1.78
        4
                          10.1
                                                3
                                                                 2.73
           number_customer_service_calls churn
        0
        1
                                         1
                                              no
        2
                                         0
                                              no
        3
                                         2
                                              no
        4
                                         3
                                              no
In [5]: # Visualizando as 5 primeiras linhas do dataset de teste
        test.head()
           Unnamed: 0 state account_length
Out[5]:
                                                   area_code international_plan
        0
                     1
                          ΗI
                                          101
                                              area_code_510
                                                                               no
        1
                     2
                          MT
                                          137
                                              area_code_510
                                                                               no
        2
                     3
                                          103 area_code_408
                          OH
                                                                               no
        3
                     4
                          NM
                                           99
                                              area_code_415
                                                                               no
        4
                     5
                          SC
                                          108 area_code_415
                                                                               no
          voice_mail_plan number_vmail_messages
                                                   total_day_minutes total_day_calls
        0
                                                                  70.9
                                                                                      123
                        no
        1
                                                 0
                                                                 223.6
                                                                                       86
                        no
        2
                                                29
                                                                 294.7
                                                                                       95
                       yes
                                                                                     123
        3
                                                 0
                                                                 216.8
                        no
        4
                                                 0
                                                                 197.4
                                                                                      78
                        no
           total_day_charge total_eve_minutes total_eve_calls total_eve_charge \
        0
                       12.05
                                           211.9
                                                                73
                                                                                18.01
                       38.01
                                           244.8
                                                               139
                                                                                20.81
        1
        2
                       50.10
                                           237.3
                                                               105
                                                                                20.17
        3
                       36.86
                                           126.4
                                                                                10.74
                                                                88
        4
                       33.56
                                           124.0
                                                               101
                                                                                10.54
           total_night_minutes total_night_calls total_night_charge
        0
                          236.0
                                                 73
                                                                   10.62
                           94.2
                                                 81
                                                                    4.24
        1
        2
                          300.3
                                                127
                                                                   13.51
        3
                          220.6
                                                 82
                                                                    9.93
        4
                          204.5
                                                107
                                                                    9.20
           total_intl_minutes total_intl_calls total_intl_charge \
        0
                                                                 2.86
                          10.6
                                                3
                                                7
        1
                           9.5
                                                                 2.57
        2
                                                6
                                                                 3.70
                          13.7
        3
                          15.7
                                                                 4.24
```

3

1

13.7

3.70

```
4
                          7.7
                                                                2.08
           number_customer_service_calls churn
        0
        1
                                        0
                                             no
        2
                                        1
                                             no
        3
                                        1
                                             no
        4
                                             no
In [6]: # Sumario geral das features do dataset de treino
        train.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3333 entries, 0 to 3332
Data columns (total 21 columns):
Unnamed: 0
                                  3333 non-null int64
state
                                  3333 non-null object
account length
                                  3333 non-null int64
                                  3333 non-null object
area_code
international_plan
                                  3333 non-null object
voice_mail_plan
                                  3333 non-null object
number_vmail_messages
                                  3333 non-null int64
total_day_minutes
                                  3333 non-null float64
                                  3333 non-null int64
total_day_calls
total_day_charge
                                  3333 non-null float64
total_eve_minutes
                                  3333 non-null float64
                                  3333 non-null int64
total_eve_calls
                                  3333 non-null float64
total_eve_charge
                                  3333 non-null float64
total_night_minutes
                                  3333 non-null int64
total_night_calls
total_night_charge
                                  3333 non-null float64
total_intl_minutes
                                  3333 non-null float64
                                  3333 non-null int64
total_intl_calls
total_intl_charge
                                  3333 non-null float64
                                  3333 non-null int64
number_customer_service_calls
churn
                                  3333 non-null object
dtypes: float64(8), int64(8), object(5)
memory usage: 546.9+ KB
In [7]: # Sumario geral das features do dataset de treino
        test.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1667 entries, 0 to 1666
Data columns (total 21 columns):
Unnamed: 0
                                  1667 non-null int64
state
                                  1667 non-null object
                                  1667 non-null int64
account_length
```

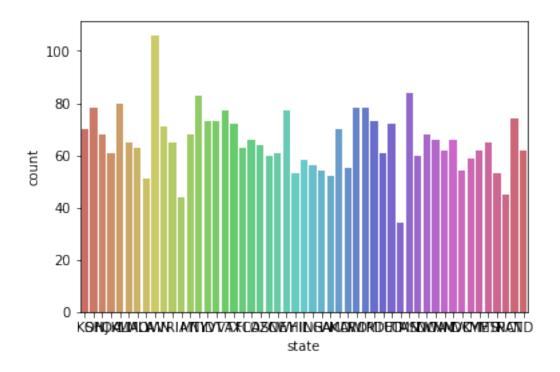
```
1667 non-null object
area_code
international_plan
                                 1667 non-null object
voice_mail_plan
                                 1667 non-null object
number_vmail_messages
                                 1667 non-null int64
total_day_minutes
                                 1667 non-null float64
total_day_calls
                                 1667 non-null int64
total_day_charge
                                 1667 non-null float64
total_eve_minutes
                                 1667 non-null float64
total_eve_calls
                                 1667 non-null int64
                                 1667 non-null float64
total_eve_charge
total_night_minutes
                                 1667 non-null float64
total_night_calls
                                 1667 non-null int64
                                 1667 non-null float64
total_night_charge
total_intl_minutes
                                 1667 non-null float64
total_intl_calls
                                 1667 non-null int64
total_intl_charge
                                 1667 non-null float64
number_customer_service_calls
                                 1667 non-null int64
                                 1667 non-null object
dtypes: float64(8), int64(8), object(5)
memory usage: 273.6+ KB
```

Vamos remover a coluna Unnamed: 0 pois se trata de um ID

```
In [8]: train.drop(columns = "Unnamed: 0", inplace = True)
    test.drop(columns = "Unnamed: 0", inplace = True)
```

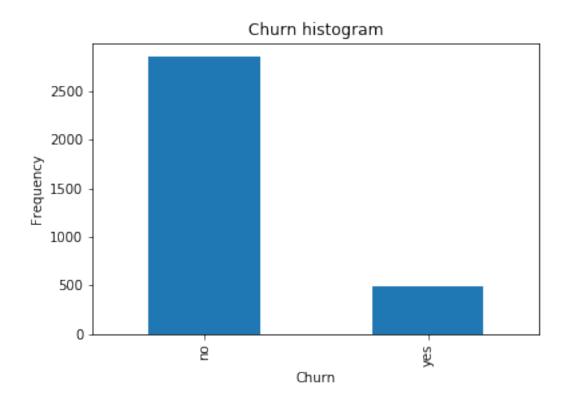
#### 2.4.1 Analise Exploratoria das variaveis do tipo object

Como está bem distribuido os registros por cada estado, esta variavel sera removida



```
In [10]: train.drop(columns = "state", inplace = True)
         test.drop(columns = "state", inplace = True)
In [11]: train['area_code'].value_counts()
Out[11]: area_code_415
                          1655
                           840
         area_code_510
                           838
         area_code_408
         Name: area_code, dtype: int64
In [12]: #train.drop(columns = "area_code", inplace = True)
         #test.drop(columns = "area_code", inplace = True)
In [13]: train['international_plan'].value_counts()
Out[13]: no
                3010
                 323
         Name: international_plan, dtype: int64
In [14]: train['voice_mail_plan'].value_counts()
Out[14]: no
                2411
                 922
         yes
         Name: voice_mail_plan, dtype: int64
```

Verificando as caracteristicas estatisticas da variavel target "churn"



Vamos transformar algumas variaveis categoricas em numericas e fazer analises estatisticas

train.replace(cleanup\_nums, inplace=True)

test.replace(cleanup\_nums, inplace=True)
train.head()

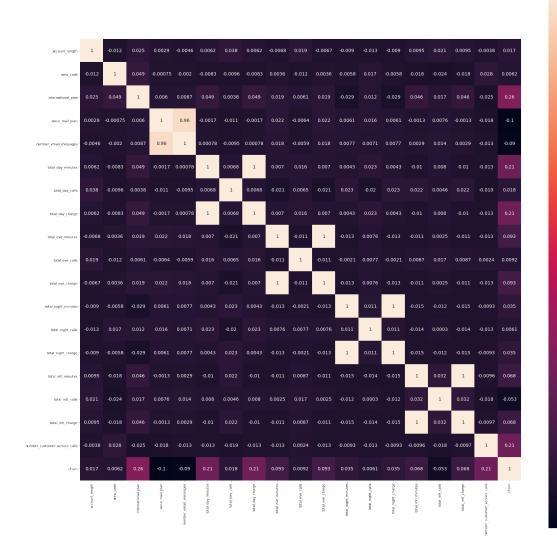
```
Out[16]:
            account_length area_code
                                        international_plan voice_mail_plan
                        128
                                    415
                                                            0
         1
                        107
                                    415
                                                            0
                                                                              1
         2
                        137
                                    415
                                                            0
                                                                              0
         3
                         84
                                    408
                                                            1
                                                                              0
         4
                         75
                                    415
                                                            1
                                                                              0
            number_vmail_messages
                                     total_day_minutes
                                                        total_day_calls
         0
                                 25
                                                  265.1
                                 26
                                                  161.6
         1
                                                                      123
         2
                                  0
                                                  243.4
                                                                      114
                                                  299.4
         3
                                  0
                                                                       71
         4
                                  0
                                                  166.7
                                                                      113
            total_day_charge total_eve_minutes total_eve_calls total_eve_charge \
         0
                        45.07
                                             197.4
                                                                  99
                                                                                  16.78
                        27.47
                                             195.5
                                                                                  16.62
         1
                                                                 103
         2
                        41.38
                                             121.2
                                                                 110
                                                                                  10.30
         3
                        50.90
                                              61.9
                                                                  88
                                                                                   5.26
         4
                        28.34
                                             148.3
                                                                 122
                                                                                  12.61
            total_night_minutes
                                   total_night_calls total_night_charge
                                                                     11.01
         0
                           244.7
                                                   91
         1
                           254.4
                                                  103
                                                                     11.45
         2
                                                  104
                                                                      7.32
                           162.6
         3
                           196.9
                                                   89
                                                                      8.86
         4
                           186.9
                                                  121
                                                                      8.41
            total_intl_minutes total_intl_calls
                                                    total_intl_charge
         0
                           10.0
                                                  3
                                                                   2.70
                           13.7
                                                  3
                                                                   3.70
         1
                                                  5
         2
                           12.2
                                                                   3.29
                                                  7
         3
                            6.6
                                                                   1.78
                           10.1
                                                  3
                                                                   2.73
            number_customer_service_calls
         0
                                           1
                                                  0
                                                  0
         1
                                           1
         2
                                          0
                                                  0
                                          2
         3
                                                  0
         4
                                          3
                                                  0
```

Verificando valores missing nos datasets de treino e teste

```
df_cols = list(pd.DataFrame(data))
             dict_x = \{\}
             for i in range(0, len(df_cols)):
                 dict_x.update({df_cols[i]: round(data[df_cols[i]].isnull().mean()*100,2)})
             return dict x
In [18]: # Dados missing no dataset de treino
         missing = percent_missing(train)
         df miss = sorted(missing.items(), key=lambda x: x[1], reverse=True)
         print('Percent of missing data')
         df miss[0:50]
Percent of missing data
Out[18]: [('account_length', 0.0),
          ('area_code', 0.0),
          ('international_plan', 0.0),
          ('voice_mail_plan', 0.0),
          ('number_vmail_messages', 0.0),
          ('total_day_minutes', 0.0),
          ('total_day_calls', 0.0),
          ('total_day_charge', 0.0),
          ('total_eve_minutes', 0.0),
          ('total_eve_calls', 0.0),
          ('total_eve_charge', 0.0),
          ('total_night_minutes', 0.0),
          ('total_night_calls', 0.0),
          ('total_night_charge', 0.0),
          ('total_intl_minutes', 0.0),
          ('total_intl_calls', 0.0),
          ('total_intl_charge', 0.0),
          ('number_customer_service_calls', 0.0),
          ('churn', 0.0)]
In [19]: train.describe().T
Out[19]:
                                                                                   25% \
                                         count
                                                      mean
                                                                   std
                                                                           min
         account_length
                                        3333.0 101.064806
                                                            39.822106
                                                                          1.00
                                                                                 74.00
                                        3333.0 437.182418 42.371290 408.00
                                                                                408.00
         area_code
         international_plan
                                        3333.0
                                                  0.096910
                                                             0.295879
                                                                          0.00
                                                                                  0.00
         voice_mail_plan
                                        3333.0
                                                  0.276628
                                                            0.447398
                                                                          0.00
                                                                                  0.00
         number_vmail_messages
                                                  8.099010 13.688365
                                                                          0.00
                                                                                  0.00
                                        3333.0
         total_day_minutes
                                        3333.0 179.775098 54.467389
                                                                          0.00
                                                                               143.70
         total_day_calls
                                        3333.0 100.435644 20.069084
                                                                          0.00
                                                                                 87.00
         total_day_charge
                                        3333.0
                                                 30.562307
                                                            9.259435
                                                                          0.00
                                                                                 24.43
         total_eve_minutes
                                        3333.0 200.980348 50.713844
                                                                          0.00 166.60
                                                                                 87.00
         total_eve_calls
                                        3333.0 100.114311 19.922625
                                                                          0.00
```

```
total_eve_charge
                               3333.0
                                         17.083540
                                                     4.310668
                                                                 0.00
                                                                         14.16
total_night_minutes
                               3333.0
                                        200.872037
                                                    50.573847
                                                                23.20
                                                                       167.00
total_night_calls
                               3333.0 100.107711 19.568609
                                                                33.00
                                                                        87.00
total_night_charge
                                          9.039325
                                                                  1.04
                                                                          7.52
                               3333.0
                                                     2.275873
total intl minutes
                                                                          8.50
                               3333.0
                                         10.237294
                                                     2.791840
                                                                 0.00
total_intl_calls
                                                                  0.00
                                                                          3.00
                               3333.0
                                          4.479448
                                                     2.461214
total_intl_charge
                               3333.0
                                          2.764581
                                                     0.753773
                                                                 0.00
                                                                          2.30
number_customer_service_calls
                               3333.0
                                          1.562856
                                                     1.315491
                                                                  0.00
                                                                          1.00
                               3333.0
                                          0.144914
                                                     0.352067
                                                                  0.00
                                                                          0.00
churn
                                   50%
                                           75%
                                                   max
account_length
                                       127.00
                                                243.00
                                101.00
area_code
                               415.00
                                       510.00
                                                510.00
international_plan
                                          0.00
                                                  1.00
                                  0.00
voice_mail_plan
                                  0.00
                                          1.00
                                                  1.00
                                 0.00
number_vmail_messages
                                         20.00
                                                 51.00
total_day_minutes
                                179.40 216.40
                                                350.80
total_day_calls
                               101.00
                                       114.00
                                                165.00
total_day_charge
                                30.50
                                         36.79
                                                 59.64
total eve minutes
                               201.40
                                       235.30
                                                363.70
total_eve_calls
                               100.00
                                       114.00
                                                170.00
total eve charge
                                         20.00
                                17.12
                                                 30.91
total_night_minutes
                               201.20 235.30
                                                395.00
total_night_calls
                               100.00 113.00
                                                175.00
total_night_charge
                                  9.05
                                        10.59
                                                 17.77
total_intl_minutes
                                                 20.00
                                 10.30
                                         12.10
total_intl_calls
                                  4.00
                                          6.00
                                                 20.00
total_intl_charge
                                  2.78
                                          3.27
                                                  5.40
number_customer_service_calls
                                  1.00
                                          2.00
                                                  9.00
churn
                                  0.00
                                          0.00
                                                  1.00
```

Vamos plotar um heatmap para verificar a correlacao das features do dataset de treino



Vamos verificar a media de cada feature relacionando com a variavel target

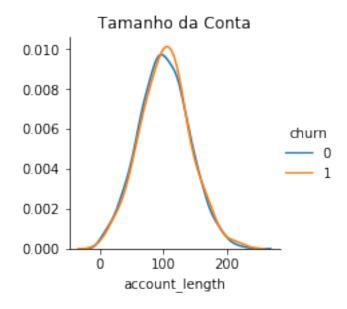
In [21]: train.groupby('churn').mean().T

Out[21]:	churn	0	1
	account_length	100.793684	102.664596
	area_code	437.074737	437.817805
	international_plan	0.065263	0.283644
	voice_mail_plan	0.295439	0.165631
	number_vmail_messages	8.604561	5.115942
	total_day_minutes	175.175754	206.914079
	total_day_calls	100.283158	101.335404
	total_day_charge	29.780421	35.175921
	total_eve_minutes	199.043298	212.410145
	total_eve_calls	100.038596	100.561077

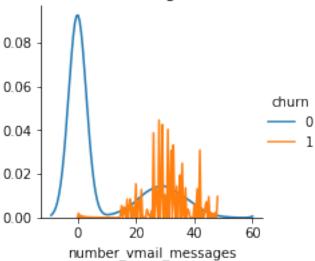
```
total_eve_charge
                                 16.918909
                                             18.054969
total_night_minutes
                                200.133193
                                            205.231677
total_night_calls
                                100.058246 100.399586
total_night_charge
                                  9.006074
                                              9.235528
total intl minutes
                                 10.158877
                                             10.700000
total_intl_calls
                                              4.163561
                                  4.532982
total_intl_charge
                                  2.743404
                                              2.889545
number_customer_service_calls
                                  1.449825
                                              2.229814
```

Obsevações: - a media de plano internacional é muito maior para clientes inativos - a media de plano de voz e mail é mais baixo para clientes inativos - a media de numero de mensagens em clientes inativos é menor - a media de ligacoes, tarifas e minutos utilizados, tanto de dia, tarde ou noite é maior em clientes inativos - number\_customer\_service\_calls é praticamente o dobro para clientes inativos

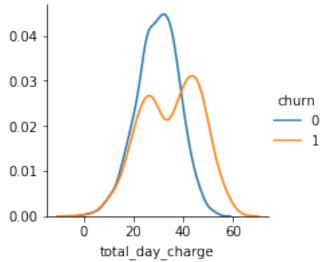
Vamos olhar mais de perto algumas features e a relacao com a variavel target

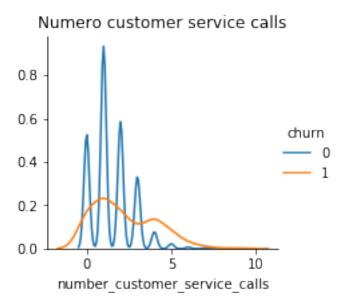


## Numero de mensagens voicemail









Analisando o grafico acima percebemos que o numero de chamadas ao servico de atendimento ao consumidor é relativamente alto em clientes que estao inativos (churn). Isso indica que os clientes que mudaram de fornecedor tentaram entrar em contato com o atendimento ao cliente, mas podem não ter recebido uma resolução satisfatória para o problema.

#### 2.5 Feature Selection - Método Ensemble

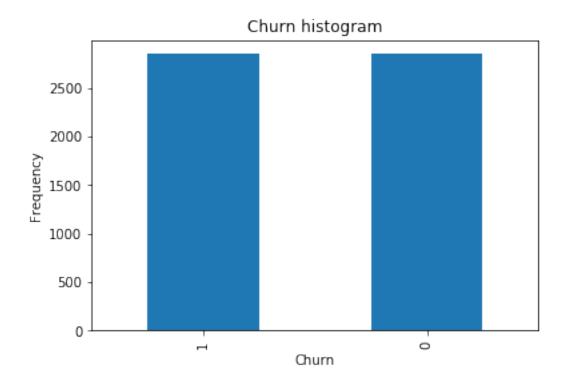
```
In [26]: # Importância do Atributo com o Extra Trees Classifier
         # Separando o array em componentes de input e output
         X = train.iloc[:,:-1]
         Y = train.churn
         # Criação do Modelo - Feature Selection
         modelo = ExtraTreesClassifier()
         modelo.fit(X, Y)
         # Convertendo o resultado em um dataframe
         df = pd.DataFrame(X.columns,columns=['Columa'])
         df['Importancia'] = pd.DataFrame(modelo.feature_importances_.astype(float))
         # Realizando a ordenacao por Importancia (Maior para Menor)
         result = df.sort_values('Importancia',ascending=False)
         # Imprimindo as 10 variaveis mais importantes
         cols_of_interest = result[1:10]['Coluna']
         print(cols_of_interest)
         # Deixando somente as colunas de interesse no df de treino
```

```
cols_of_interest = cols_of_interest.append(pd.Series(['churn']))
         new_train = train[cols_of_interest]
17
     number_customer_service_calls
7
                   total_day_charge
                 international_plan
2
10
                   total_eve_charge
8
                  total_eve_minutes
                   total_intl_calls
15
14
                 total_intl_minutes
16
                  total_intl_charge
                total_night_minutes
11
Name: Coluna, dtype: object
```

## 2.6 Feature Engineering

Resolvendo o problema de Overfitting da variavel TARGET utilizando o OverSampling ou Resample

```
In [27]: # Resolvendo problema de Overfitting utilizando o OverSampling
         # Separando o array em componentes de input e output
         X = new_train.iloc[:,:-1]
         Y = new_train.churn
         # Aplicando a funcao SMOTE
         # SMOTE eh um metodo de oversampling. Ele cria exemplos sinteticos da classe minorita
         sm = SMOTE(random_state=0)
         X_treino_res, Y_treino_res = sm.fit_sample(X, Y)
         np.bincount(Y_treino_res)
Out[27]: array([2850, 2850])
In [28]: # Distribuição das classes (variavel TARGET) apos aplicar OverSampling
         pd.value_counts(Y_treino_res).plot.bar()
         plt.title('Churn histogram')
         plt.xlabel('Churn')
         plt.ylabel('Frequency')
         # Visualizando um df com quantidade e percentual da variavel Churn
         df = pd.DataFrame(pd.value_counts(Y_treino_res), columns=['Churn'])
         df['%'] = 100*df['Churn']/Y_treino_res.shape[0]
Out [28]:
           Churn
                      %
             2850 50.0
             2850 50.0
```

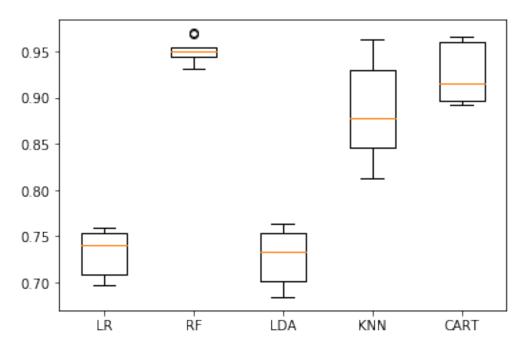


### 2.7 Criação e Validação dos Modelos de Machine Learning

```
In [29]: # Criacao dos modelos de Classificacao
         # Separando o array em componentes de input e output (dados com oversampling)
         X = X_treino_res
         Y = Y_treino_res
         # Aplicando a mesma escala nos dados
         X = MinMaxScaler().fit_transform(X)
         # Padronizando os dados (O para a média, 1 para o desvio padrão)
         X = StandardScaler().fit_transform(X)
         # Definindo os valores para o número de folds
         num_folds = 10
         seed = 10
         # Preparando a lista de modelos
         modelos = []
         modelos.append(('LR', LogisticRegression()))
         modelos.append(('RF', RandomForestClassifier()))
         modelos.append(('LDA', LinearDiscriminantAnalysis()))
         modelos.append(('KNN', KNeighborsClassifier()))
```

```
modelos.append(('CART', DecisionTreeClassifier()))
         #modelos.append(('SVM', SVC())) # comentei este modelo pois demora bastante e nao eh n
         # Avaliando cada modelo em um loop
         resultados = []
         nomes = []
         for nome, modelo in modelos:
             kfold = KFold(n_splits = num_folds, random_state = seed)
             cv_results = cross_val_score(modelo, X, Y, cv = kfold, scoring = 'accuracy')
             resultados.append(cv_results)
             nomes.append(nome)
             msg = "%s: %f (%f)" % (nome, cv_results.mean(), cv_results.std())
             print(msg)
         # Boxplot para comparar os algoritmos
         fig = plt.figure()
         fig.suptitle('Comparacao de Algoritmos de Classificacao')
         ax = fig.add_subplot(111)
         plt.boxplot(resultados)
         ax.set_xticklabels(nomes)
         plt.show()
LR: 0.732456 (0.023917)
RF: 0.950702 (0.011328)
LDA: 0.727544 (0.028860)
KNN: 0.886316 (0.051698)
CART: 0.926316 (0.031197)
```

## Comparacao de Algoritmos de Classificacao



### 3 Otimizando Performance do modelo

## 3.1 Grid Search Parameter Tuning

Este método realiza metodicamente combinações entre todos os parâmetros do algoritmo, criando um grid. Vamos usar este método utilizando o algoritmo de Regressão Logística, conforme recomendado na especificação

```
In [30]: # Definindo os valores que serão testados
    valores_grid = {'penalty': ['11','12'], 'C': [0.001,0.01,0.1,1,10,100,1000]}

# Criando o modelo
    modelo = LogisticRegression()

# Criando o grid
    grid = GridSearchCV(estimator = modelo, param_grid = valores_grid)
    grid.fit(X, Y)

# Print do resultado
    print("Acurácia: %.3f" % (grid.best_score_ * 100))
    print("Melhores Parâmetros do Modelo:\n", grid.best_estimator_)

Acurácia: 77.246

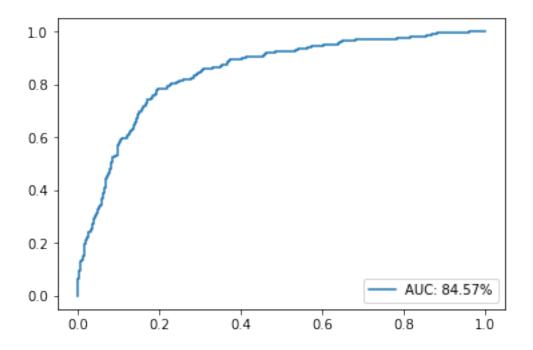
Melhores Parâmetros do Modelo:
```

```
LogisticRegression(C=1000, class_weight=None, dual=False, fit_intercept=True,
    intercept_scaling=1, max_iter=100, multi_class='warn',
    n_jobs=None, penalty='12', random_state=None, solver='warn',
    tol=0.0001, verbose=0, warm_start=False)
```

### 3.2 Utilizando o modelo Logistic Regression para fazer previsoes no dataset de teste

```
In [31]: # Fazendo previsões com o modelo Logistic Regression
         # Separando o array em componentes de input e output
         X_teste = test.iloc[:,:-1]
         Y_teste = test.churn
         # Aplicando a mesma escala nos dados
         X_teste = MinMaxScaler().fit_transform(X_teste)
         # Padronizando os dados (O para a média, 1 para o desvio padrão)
         X_teste = StandardScaler().fit_transform(X_teste)
         # Fit do modelo com melhores parametros
         modelo_otm = grid.estimator
         modelo_otm.fit(X_teste, Y_teste)
         # Fazendo previsões no modelo de treino
         y_pred = modelo_otm.predict(X_teste)
         previsoes = [round(value) for value in y_pred]
         # Avaliando as previsões
         accuracy = accuracy_score(Y_teste, previsoes)
         print("Acurácia: %.2f%%" % (accuracy * 100.0))
Acurácia: 87.64%
```

Realizando previsoes no dataset de teste a acurácia do modelo de Regressa<br/>o Logistica chegou a 87%



A pontuação da AUC para este caso é de 84%. AUC 1 representa um classificador perfeito e 0,5 representa um classificador sem valor. Sendo assim, é um ótimo resultado do modelo

# 4 Verificando o relatório de classificação

		precision	recall	f1-score	support
	0	0.89	0.98	0.93	1443
	1	0.61	0.22	0.32	224
micro	avg	0.88	0.88	0.88	1667
macro		0.75	0.60	0.63	1667
weighted		0.85	0.88	0.85	1667

```
Confusion Matrix
[[1412
        317
 Γ 175
        4911
In [35]: # Criacao de função para criar um plot para a confusion matrix
         \#\ http://scikit-learn.org/stable/auto\_examples/model\_selection/plot\_confusion\_matrix.
         def plot_confusion_matrix(cm,
                                   target_names,
                                   title='Confusion matrix',
                                   cmap=None,
                                   normalize=True):
             accuracy = np.trace(cm) / float(np.sum(cm))
             misclass = 1 - accuracy
             if cmap is None:
                 cmap = plt.get_cmap('Blues')
             plt.figure(figsize=(8, 6))
             plt.imshow(cm, interpolation='nearest', cmap=cmap)
             plt.title(title)
             plt.colorbar()
             if target_names is not None:
                 tick_marks = np.arange(len(target_names))
                 plt.xticks(tick_marks, target_names, rotation=45)
                 plt.yticks(tick_marks, target_names)
             if normalize:
                 cm = cm.astype('float') / cm.sum(axis=1)[:, np.newaxis]
             thresh = cm.max() / 1.5 if normalize else cm.max() / 2
             for i, j in itertools.product(range(cm.shape[0]), range(cm.shape[1])):
                 if normalize:
                     plt.text(j, i, "{:0.4f}".format(cm[i, j]),
                              horizontalalignment="center",
                              color="white" if cm[i, j] > thresh else "black")
                 else:
                     plt.text(j, i, "{:,}".format(cm[i, j]),
                              horizontalalignment="center",
                              color="white" if cm[i, j] > thresh else "black")
```

```
plt.tight_layout()
plt.ylabel('True label')
plt.xlabel('Predicted label\naccuracy={:0.4f}; misclass={:0.4f}'.format(accuracy, plt.show()
```

normalize = False, target\_names = ['0', '1'], title = "Confusion Matrix")

